

Аннотация

Применение методов машинного обучения в статистическом анализе

Назаров Константин Олегович

Статические анализаторы широко используются в промышленности для нахождения и исправления уязвимостей в коде в процессе разработки, тем самым улучшая качество кода и упрощая дальнейшую разработку. Однако их применение ограничивается тем, что на больших и сложных кодовых базах статические анализаторы выдают большое количество false positives наряду с предупреждениями о действительных уязвимостях. Поэтому значительная часть данной работы посвящена тому, чтобы применить методы машинного обучения для классификации и приоритизации сообщений статического анализатора, что позволит сократить время, затрачиваемое разработчиками на ручную обработку всех сообщений анализатора. Основной проблемой при обучении подобного классификатора является составление тренировочного датасета, т.к. неочевиден алгоритм разметки данных и признаки для обучающей выборки. Также большим фактором является скорость генерации: признаки не должны вычисляться долго, т.к. сам статический анализ занимает очень большое время (для относительно простых анализаторов время работы примерно в

2 раза превышает время компиляции, но может быть и много больше [13]). В данной работе рассматривается способ генерации датасета при помощи тестовых сюит для статических анализаторов (т.е. репозиторий с "образцовыми" программами, специально написанными для тестирования статических анализаторов), а также показывается, что включение в обучающий датасет token-based представления кода помогает увеличить способность к распознаванию разных шаблонов ошибок, не увеличивая при этом сложности генерации датасета. Данные для обучения были получены путем применения нескольких статических анализаторов к кодовой базе Juliet C/C++ Test Suite v1.3. Разметка была произведена автоматически из метаданных тестовой сюиты. Полученный датасет был использован для обучения двух моделей: decision tree и gradient boosting, предоставляемых библиотекой xgboost для python3. Полученные классификаторы имеют высокую точность на тестовой выборке ($\approx 96\%$). Также в работе был предложен альтернативный метод генерации датасета, призванный решить проблемы использованного метода. Применение альтернативного метода является предметом дальнейших исследований.

Оглавление

1	Введение	5
2	Постановка задачи	9
3	Обзор существующих решений и выводы	11
4	Исследование и построение решения задачи	15
5	Описание практической части	17
6	Заключение	19

Глава 1

Введение

Обозначения и сокращения

1. False Positive, FP - ошибка бинарной классификации, при которой классификатор ошибочно предсказывает положительный результат (например диагноз болен, когда болезни на самом деле нет)
2. Датасет - это обработанная и структурированная информация в табличном виде. Строки такой таблицы называются объектами, а столбцы – признаками (фичами)
3. Token-Based представление - представление кода в виде последовательности токенов, получаемых в результате лексического анализа
4. Тестовая сюита - специализированный набор тестов
5. Abstract Syntax Tree, AST - представление исходного кода в виде дерева абстрактного синтаксиса

6. Application Programming Interface, API - описание способов (набор классов, процедур, функций, структур или констант), которыми одна компьютерная программа может взаимодействовать с другой программой
7. Common Weakness Enumeration, CWE [19] - Список уязвимостей программного и аппаратного обеспечения. Является общепринятым языком для описания природы уязвимости
8. NIST - The National Institute of Standards and Technology
9. SATE - Static Analysis Tool Expositions

Введение

Статические анализаторы широко используются в промышленности для нахождения и исправления уязвимостей в коде в процессе разработки, тем самым улучшая качество кода и упрощая дальнейшую разработку. Однако их применение ограничивается Множеством факторов. Статья "A Few Billion Lines of Code Later. Using Static Analysis to Find Bugs in the Real World"[4] раскрывает множество проблем с применением статических анализаторов на практике, среди которых: большое количество false positives (35% – 91% [11]) на сложных или больших кодовых базах; пользователи, помечающие непонятные им сообщения как ложные; а также сложность обработки большого количества ошибок пользователем, которая приводит к тому, что анализаторы выдают меньше сообщений, чем могли бы. В связи с этим, Moritz Marc Beller с коллегами [3] обнаружили, что на

практике очень малое число проектов с открытыми исходным кодом интегрирует статические анализаторы в процесс разработки. Также большая часть проектов не поддерживает правила, что предупреждения компиляции должны рассматриваться как ошибки. Поэтому значительная часть данной работы посвящена тому, чтобы применить методы машинного обучения для классификации и приоритизации сообщений статического анализатора, что позволит сократить время, затрачиваемое разработчиками на ручную обработку всех сообщений анализатора а также облегчит эффективное использование анализаторов на практике. Основной проблемой при обучении подобного классификатора является составление тренировочного датасета, т.к. неочевиден алгоритм разметки данных и признаки для обучающей выборки. Также большим фактором является скорость генерации: признаки не должны вычисляться долго, т.к. сам статический анализ занимает очень большое время (для относительно простых анализаторов время работы примерно в 2 раза превышает время компиляции, но может быть и много больше [13]). В промышленности эта проблема решается тем, что датасет зачастую имеется [15] или может быть легко получен из статистики использования или из истории проекта [17]. В данной работе рассматривается способ генерации датасета при помощи тестовых сьюит для статических анализаторов [9] (т.е. репозитории с "образцовыми" программами, специально написанными для тестирования статических анализаторов), а также показывается, что включение в обучающий датасет token-based представления кода помогает увеличить способность к распознаванию разных шаблонов ошибок, не увеличивая при этом сложности генерации датасета. Данные для обучения были получены путем

применения нескольких статических анализаторов к кодовой базе Juliet C/C++ Test Suite [1]. Разметка была произведена автоматически из метаданных тестовой сюиты. Полученный датасет был использован для обучения двух моделей, которые впоследствии были протестированы на тестовой выборке.

Глава 2

Постановка задачи

Цель и задачи

Основной целью данной работы является сокращение времени, затрачиваемого разработчиком на обработку результатов статического анализа. Также важной целью является применение полученных результатов для анализа работы статического анализатора и его дальнейшей настройки. Для достижения обозначенной цели требуется решить следующие задачи:

1. Определить признаки для будущего датасета
2. Определить метод генерации датасета и его разметки. Собрать данные
3. Обучить классификатор сообщений статического анализатора
4. Проанализировать полученные результаты

Требования к решению

Для того, чтобы результат считался удовлетворительным и применимым на больших масштабах, решения для поставленных задачи должны удовлетворять следующим требованиям:

1. Сложность извлечения признаков не должна превосходить сложности статического анализа
2. Разметка датасета должна быть автоматизированной, т.к. ручная разметка занимает слишком долгое время и требует наличия проанализированной большой кодовой базы [2]
3. Классификатор не должен быть ограничен конкретными анализаторами, т.е. должен иметь возможность обработать и классифицировать предупреждение от любого анализатора после необходимой обработки

Глава 3

Обзор существующих решений и выводы

Необходимость поддержки множества анализаторов обуславливается еще и тем, что каждый анализатор покрывает лишь конечное число уязвимостей, упуская остальные[7] [8] [4]. Поэтому для получения наиболее полного по типам ошибок датасета необходимо уметь обрабатывать сообщения от разных анализаторов. Решением данной проблемы является приведение всех кодов ошибок к кодам CWE [19] на этапе обработки сообщения и использование соответствующего кода CWE в датасете при обучении и классификации. Таким образом, добавление поддержки нового анализатора заключается в трансляции кода ошибок анализатора в CWE. Более подробно данный метод будет описан в дальнейшем в соответствующем разделе.

Sarah Heckman и Laurie Williams в своем исследовании[11] выделили следующие характеристики, используемые в наиболее релевантных работах о классификаторах, кодобных тому, который явля-

ется целью данного диплома:

1. Характеристики ошибки - атрибуты предупреждения, сгенерированного статистиким анализатором, например: тип ошибки (double free, etc.), местоположение в коде (файл, класс, функция, строка, etc.), а также приоритет, который анализатор присвоил ошибке
2. Характеристики кода - метрики кода, в котором содержится предупреждение. Эти метрики могут быть извлечены при помощи дополнительного анализа или из самого кода (цикломатическая сложность, количество строк в файле, etc.)
3. Метрики репозитория с исходным кодом - атрибуты репозитория с исходным кодом (история коммитов, частота изменения кода, история ревью, etc.)
4. Метрики базы данных с багами - информация о багах может быть связана с изменениями в исходном коде для того, чтобы идентифицировать уязвимость и необходимые исправления
5. Метрики динамического анализа - гибридное использование статического и динамического анализа может помочь митигировать затраты, связанные с исполнением каждой техники анализа

В данной работе внимание было сосредоточено целиком на первых двух пунктах: характеристики ошибки и характеристики кода. Изучив соответствующие статьи, было выяснено, что основными характеристиками кода для последующего анализа являются метрики, такие как число вложенности функции, число условных переходов,

цикломатическая сложность, etc [9]. Однако все эти метрики являются метаданными, которые лишь характеризуют код в целом, не давая понятия о его структуре. Для того, чтобы каким либо образом анализировать структуру кода обычно используется представление AST[16]. Такой подход хорош для таких языков как Java, Python, где AST может быть легко получено. Для получения же AST в C/C++ необходима полная компиляция проекта. Т.к. каждый проект имеет свою систему для сборки, то невозможно описать данную процедуру единым простым путем. Поэтому в данной работе был опробован подход на основе token-based представления кода, предложенного в [16] для задач определения стиля проекта и вывода правил использования API. Идея состоит в том, что хоть представление в виде токенов и является неточным, но отфильтровав его, и анализируя наряду с метаданными кода, может быть получена более полная картина, нежели чем при использовании только метаданных. Более подробно этот подход будет описан в дальнейшем в соответствующем разделе.

Juliet Test Suite - это набор рукописных тестов, предназначенных для валидации эффективности различных статистических анализаторов[1]. Ugur Кос с коллегами уже использовали эту тестовую сюиту для обучения своих моделей классификации. Также данный метод был использован Lori Flynn с коллегами [9]. Подход к генерации датасета, используемый в данной работе был позаимствован из этих работ.

Глава 4

Исследование и построение решения задачи

Здесь надо декомпозировать большую задачу из постановки на подзадачи и продолжать этот процесс, пока подзадачи не станут достаточно простыми, чтобы их можно было бы решить напрямую (например, поставив какой-то эксперимент или доказав теорему) или найти готовое решение.

Глава 5

Описание практической части

Если в рамках работы писался какой-то код, здесь должно быть его описание: выбранный язык и библиотеки и мотивы выбора, архитектура, схема функционирования, теоретическая сложность алгоритма, характеристики функционирования (скорость/память).

Глава 6

Заключение

Здесь надо перечислить все результаты, полученные в ходе работы. Из текста должно быть понятно, в какой мере решена поставленная задача.

Список литературы

- [1] NSA Center for Assured Software. *Juliet Test Suite*. 2022. URL: <https://samate.nist.gov/SARD/test-suites/112> (дата обр. 28.04.2022).
- [2] Nathaniel Ayewah и William W. Pugh. “The Google FindBugs fixit”. В: *ISSTA '10*. 2010.
- [3] Moritz Marc Beller и др. “Analyzing the State of Static Analysis: A Large-Scale Evaluation in Open Source Software”. В: *2016 IEEE 23rd International Conference on Software Analysis, Evolution, and Reengineering (SANER)* 1 (2016), с. 470—481.
- [4] Al Bessey и др. “A few billion lines of code later”. В: *Communications of the ACM* 53 (2010), с. 66—75.
- [5] bright-tools. *CCSM repository*. 2022. URL: <https://github.com/bright-tools/ccsm> (дата обр. 28.04.2022).
- [6] Clang. *Clang Static Analyzer documentation*. 2022. URL: <https://clang-analyzer.llvm.org/> (дата обр. 28.04.2022).
- [7] Aurélien Delaitre, Vadim Okun и Elizabeth N. Fong. “Of Massive Static Analysis Data”. В: *2013 IEEE Seventh International Conference*

- on Software Security and Reliability Companion* (2013), с. 163—167.
- [8] Aurelien Delaitre и др. “Evaluating Bug Finders: Test and Measurement of Static Code Analyzers”. en. В: *Complex FaULTs и Failures in Large Software Systems (COUFLESS)*, Firenze, -1, 2015-05-23 2015. URL: https://tsapps.nist.gov/publication/get_pdf.cfm?pub_id=918370.
- [9] Lori Flynn, William Snaveley и Zachary Kurtz. “Test Suites as a Source of Training Data for Static Analysis Alert Classifiers”. В: (май 2021).
- [10] Lori Flynn и др. “Prioritizing alerts from multiple static analysis tools, using classification models”. В: (май 2018). DOI: 10.1145/3194095.3194100.
- [11] Sarah Heckman и Laurie Williams. “A systematic literature review of actionable alert identification techniques for automated static code analysis”. В: *Information and Software Technology* 53.4 (2011). Special section: Software Engineering track of the 24th Annual Symposium on Applied Computing, с. 363—387. ISSN: 0950-5849. DOI: <https://doi.org/10.1016/j.infsof.2010.12.007>. URL: <https://www.sciencedirect.com/science/article/pii/S0950584910002235>.
- [12] Ugur Koc и др. “Learning a Classifier for False Positive Error Reports Emitted by Static Code Analysis Tools”. В: *MAPL 2017* (2017), с. 35—42. DOI: 10.1145/3088525.3088675. URL: <https://doi.org/10.1145/3088525.3088675>.

- [13] David Malcolm. *Static analysis in GCC 10*. 2022. URL: <https://gcc.gnu.org/wiki/DavidMalcolm/StaticAnalyzer> (дата обр. 28.04.2022).
- [14] Michael Pradel и Koushik Sen. “DeepBugs: A Learning Approach to Name-Based Bug Detection”. В: *Proc. ACM Program. Lang.* 2.OOPSLA (окт. 2018). DOI: 10.1145/3276517. URL: <https://doi.org/10.1145/3276517>.
- [15] Joseph R. Ruthruff и др. “Predicting Accurate and Actionable Static Analysis Warnings: An Experimental Approach”. В: 2018.
- [16] Andrey Y. Shedko и др. “Applying probabilistic models to C++ code on an industrial scale”. В: *Proceedings of the IEEE/ACM 42nd International Conference on Software Engineering Workshops* (2020).
- [17] Anshul Tanwar и др. “Assessing Validity of Static Analysis Warnings using Ensemble Learning”. В: (апр. 2021).
- [18] Cppcheck Team. *cppcheck static source code analysis tool for C and C++ code*. 2022. URL: <http://cppcheck.net/> (дата обр. 21.05.2022).
- [19] CWE Team. *Common weakness enumeration: A community-developed dictionary of software weakness types*. 2022. URL: <http://cwe.mitre.org/documents/schema/index.html> (дата обр. 28.04.2022).